

Digit Recognition

Participantes:

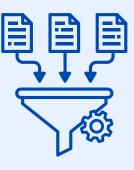
Fernando Javier López Cerezo Emilio Gómez Esteban Alberto Trigueros Postigo María Peinado Toledo



Resumen del proyecto

El conjunto de datos MNIST es un recurso clásico para la clasificación de imágenes de dígitos escritos a mano, utilizado en la investigación y enseñanza de la visión artificial. En esta proyecto, el objetivo es clasificar correctamente las imágenes de dígitos. Mientras debemos experimentar con diferentes algoritmos para entender su rendimiento y compararlos.

Objetivos







Procesamiento de datos del problema

Resolver el problema con distintos modelos de machine learning

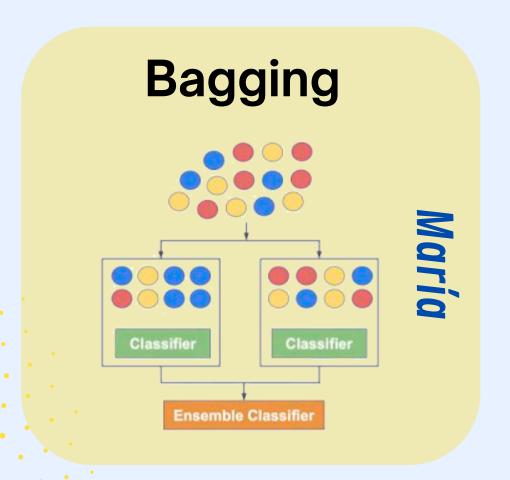
Determinar el mejor modelo con mayor accuracy y menor consumo de recursos

SVM ...

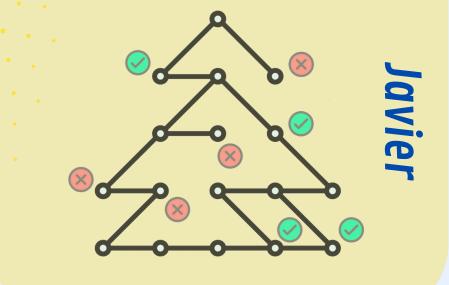
Rpart X>A NO SI Clase 1 Z > B NO SI Clase 2 Clase 1

Modelos











Procesamiento de datos

Carga

```
train <- read.csv("train.csv")
test <- read.csv("test.csv")</pre>
```

Inspección

```
prop.table(table(train$label)) * 100
train$label <- factor(train$label)</pre>
```

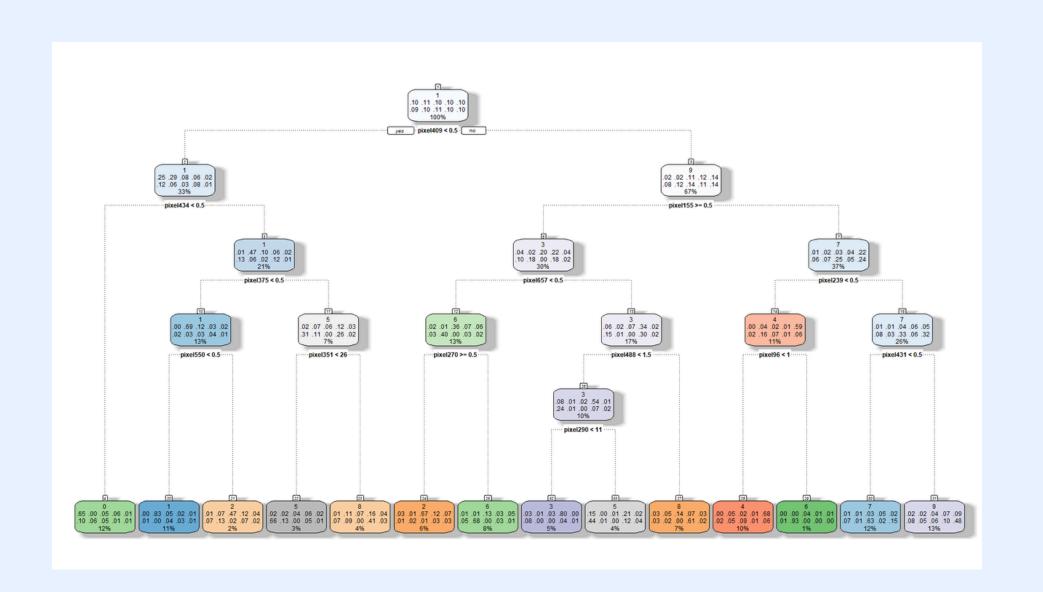
División

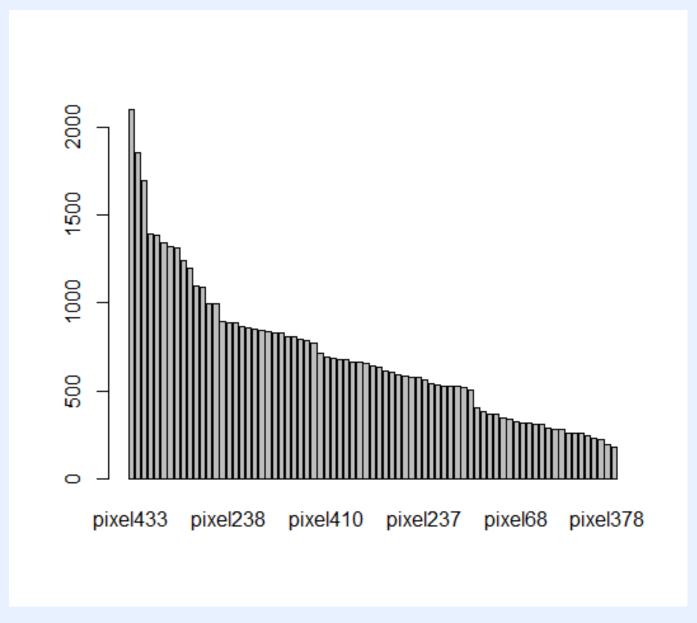
```
d_ size <- nrow ( train )
dtest _ size <- ceiling (0.2 * d_ size )
samples <- sample (1: d_size , d_size ,
replace = FALSE )
indexes <- samples [1: dtest _ size ]
dtrain <- train [ - indexes ,]
dtest <- train [ indexes ,]</pre>
```

Train Test **20%**

```
start _ time <- Sys . time ()
tree = rpart ( label ~. , data = dtrain , method = " class ")
end _ time <- Sys . time ()

matrizconfusiontree <- table ( predict ( tree , newdata = dtest , type = " class ") ,
dtest $ label )
accuracytree <- sum ( diag ( matrizconfusiontree ) ) / sum ( matrizconfusiontree )
accuracytree
fancyRpartPlot ( tree )
barplot ( tree $ variable . importance )</pre>
```





Random Forest

```
start _ time <- Sys . time ()
rf. model <- randomForest ( label ~ . , data = dtrain , ntree = 5)
end _ time <- Sys . time ()
save (rf.model , file ="rf5 .rda ")
end _ time - start _ time

rf. predict <- predict (rf.model , dtest )
matrizconfusionRF <- table (rf. predict , dtest $ label )
accuracyRF <- sum( diag ( matrizconfusionRF ) ) / sum( matrizconfusionRF )
accuracyRF</pre>
```

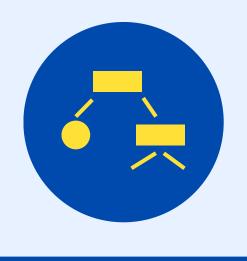
```
start _ time <- Sys . time ()
filter <- ksvm ( label ~ . , data = dtrain , kernel = " polydot ", kpar = list
  ( degree = 3) , cross = 3)
end _ time <- Sys . time ()

matrizconfusionKSVMpol <- table ( predict ( filter , dtest ) , dtest $ label )
accuracyksvmpol <- sum(diag (matrizconfusionKSVMpol)) / sum(matrizconfusionKSVMpol)

# Mostrar resultados
print ( matrizconfusionKSVMpol )
cat (" Accuracy del modelo :", accuracyksvmpol , "\n")
cat (" Tiempo de ejecución SVM :", end_time - start _time , "\n")</pre>
```

```
start time <- Sys . time ()</pre>
Modelo _ AdaBag <- bagging ( label ~. , data = dtrain , na. action = na.omit ,
mfinal =9 , control = rpart . control ( cp = 0.001 , minsplit =7) )
end _ time <- Sys . time ()</pre>
matrizconfusionBag <- table ( dtest [ , " label "] , predict ( Modelo _AdaBag,</pre>
                   newdata = dtest , type = " class ")$ class )
accuracyBag <- sum( diag ( matrizconfusionBag ) ) / sum( matrizconfusionBag )</pre>
print ( matrizconfusionBag )
cat (" Accuracy del modelo :", accuracyBag , "\n")
cat (" Tiempo de ejecución Bagging :", end_time - start _time , "\n")
```

Resultados obtenidos de los modelos



Accuracy: 0.6333 Time: 53.2402 seg

Rpart



Random Forest

5 Árboles

Accuracy: 0.9104

Time: 24.9980 seg

50 Árboles

Accuracy: 0.9632

Time: 4.4706 min

100 Árboles

Accuracy: 0.9663

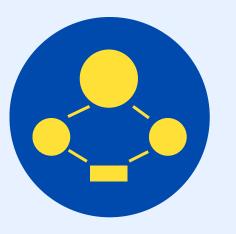
Time: 16.855 min



SVM

Accuracy: 0.9748

Time: 35.1554 min

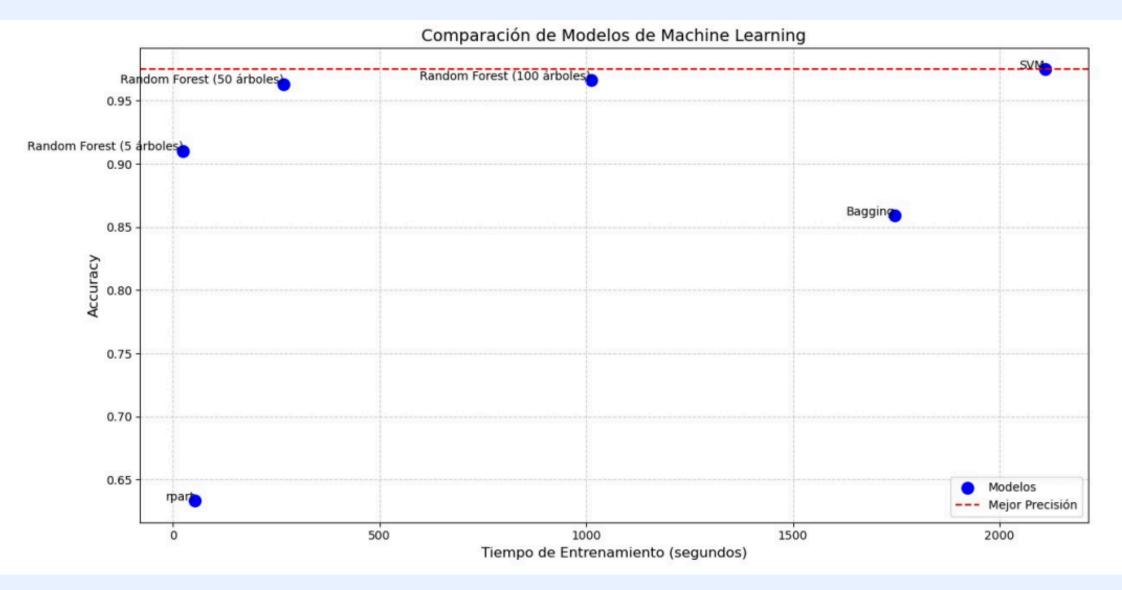


Bagging

Accuracy: 0.8594

Time: 29.1157 min

Conclusión



Depende de los requerimientos del problema

Maximizar precisión sin tener en cuenta el tiempo

SVM

Compromiso entre precisión y eficiencia computacional

Random Forest
50 Árboles

Maximizar eficiencia computacional con menor eficiencia

Rpart